连续最优化建模与应用

（第二章）

王慧慧
huihuiwang@njust.edu.cn
计算机科学与工程学院

目录

01 基本概念
02 无约束最优性条件
03 使用导数的优化方法
04 约束最优性条件及方法

01 基本概念

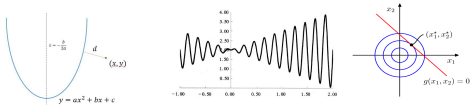
数学模型

数学模型的一般形式：

$$\begin{cases} min & f(x) \\ s.t. & g_i(x) \geq 0,\ i = 1,\cdots,p \\ & h_i(x) = 0,\ j = 1,\cdots,q \end{cases}$$

其中，$x = (x_1, x_2, \cdots, x_n)^T, f(x), g_i(x), h_j(x)$为$x$的实值函数

连续优化问题：决策变量可以在实数范围内**连续变化**，如求解函数的最小值或最大值问题。



数学模型

数学模型的一般形式：

$$\begin{cases} min & f(x) \\ \text{s.t.} & g(x) \geq 0 \\ & h(x) = 0 \end{cases}$$

$h(x) = \left(h_1(x), \cdots, h_q(x)\right)^T \quad g(x) = \left(g_1(x), \cdots, g_p(x)\right)^T$

(1) 若$f(x), g_i(x), h_j(x)$皆为线性函数，即为线性规划(LP)；

(2) 若$f(x), g_i(x), h_j(x)$至少一个为非线性，即为非线性规划(NLP)；

(3) 若没有$g_i(x), h_j(x)$称为无约束最优化问题；否则称为约束最优化问题

若x在$X = \left\{x \in R^n \middle| \begin{matrix} g_i(x) \geq 0, i = 1,\cdots,p \\ h_i(x) = 0, j = 1,\cdots,q \end{matrix}\right\}$内，称$x$为优化问题的可行解或者可行点.

最优解和极小点

定义：对于最优化问题，若$x^* \in \mathcal{X}$，并且有

$$f(x^*) \leq f(x), \forall x \in \mathcal{X}$$

称x^*是最优化问题的整体最优解或整体极小点，

称$f(x^*)$是最优化问题的整体最优值或整体极小值

如果有

$$f(x^*) < f(x), \forall x \in \mathcal{X}, x \neq x^*$$

称x^*是最优化问题的严格整体最优解或严格整体极小点，

称$f(x^*)$是最优化问题的严格整体最优值或严格整体极小值

最优解和极小点

定义：对于最优化问题，若$x^* \in \mathcal{X}$，并且存在x^*的邻域$N_\delta(x^*)=\{x \in R^n \mid \|x - x^*\| < \delta\}$使：

$$f(x^*) \leq f(x), \forall x \in N_\delta(x^*) \cap \mathcal{X}$$

称x^*是的局部最优解或局部极小解，

称$f(x^*)$是最优化问题的局部最优值或局部极小值。

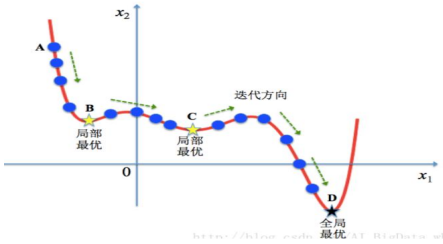
如果有：

$$f(x^*) < f(x), \forall x \in N_\delta(x^*) \cap \mathcal{X},\ x \neq x^*$$

称x^*是最优化问题的严格局部最优解或严格局部极小点。

称$f(x^*)$是最优化问题的严格局部最优值或严格局部极小值。

最优解和极小点



凸函数

凸函数

设$S \subset R^n$是非空凸集，函数$f: S \to R$，若对任意$x_1, x_2 \in S$和任意的$\lambda \in (0,1)$都有

$$f(\lambda x_1 + (1-\lambda)x_2) \leq \lambda f(x_1) + (1-\lambda) f(x_2)$$

则称f是S上的凸函数。

若上面的不等式恒有

$$f(\lambda x_1 + (1-\lambda)x_2) < \lambda f(x_1) + (1-\lambda) f(x_2)$$

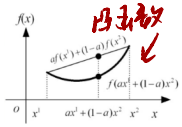
严格成立，则称f是S上的严格凸函数。

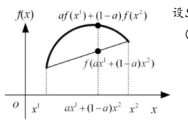
凸函数

凸函数

若$-f$是S上的凸函数，则称f是S上的凹函数。

若$-f$是S上的严格凸函数，则称f是S上的严格凹函数。





设$S\subset R^n$是非空开凸集，$f:S\to R$可微，则：

（1）f是S上的凸函数⇔

$\nabla f(x^1)^T(x^2-x^1)\le f(x^2)-f(x^1),$

（2）$f:S\to R^1$二阶连续可导，

则f是S上的凸函数 ⇔

$\nabla^2 f(x)$在S上是半正定的

任意两点的函数值的连线上的点都在曲线的上方

梯度与Hessian矩阵

梯度定义：$f(x)$是定义在$R^n\to R$的可微函数。$f(x)$的n个偏导数为分量的向量成为$f(x)$的梯度。

$$\nabla f(x)=\left[\frac{\partial f(x)}{\partial x_1},\frac{\partial f(x)}{\partial x_2},\cdots,\frac{\partial f(x)}{\partial x_n}\right]^T$$

性质：设$f(x)$在定义域内有连续梯度，则梯度有以下两个重要性质：

（1）函数在某点的梯度不为零，则该梯度方向必与过该点的等值面垂直；

（2）梯度方向是函数具有最大变化率的方向（负梯度方向也叫最速下降方向）

梯度与Hessian矩阵

例：试求目标函数$f(x_1,x_2)=3x_1^2-4x_1x_2+x_2^2$

在点$x=[0,1]^T$处的最速下降方向，并求沿这个方向移动一个单位长度后新点的取值。

解：由于$\frac{\partial f}{\partial x_1}=6x_1-4x_2$，$\frac{\partial f}{\partial x_2}=-4x_1+2x_2$

则函数在$x=[0,1]^T$处的最速下降方向是

$$P=-\nabla f(x)=\begin{bmatrix}-\frac{\partial f}{\partial x_1}\\-\frac{\partial f}{\partial x_2}\end{bmatrix}_{\substack{x_1=0\\x_2=1}}=\begin{bmatrix}-6x_1+4x_2\\4x_1+2x_2\end{bmatrix}_{\substack{x_1=0\\x_2=1}}=\begin{bmatrix}+4\\-2\end{bmatrix}$$

单位向量$e=P/||P||=\begin{bmatrix}+4\\-2\end{bmatrix}/\sqrt{16+4}$　　$x_{new}=x+e=\begin{bmatrix}2/\sqrt{5}\\1-1/\sqrt{5}\end{bmatrix}$

梯度与Hessian矩阵

Hessian矩阵

多元函数$f(x):R^n\to R$关于x的二阶导数，称为$f(x)$的Hessian矩阵

$$\nabla^2 f(x)=\nabla(\nabla f(x))=\begin{bmatrix}\frac{\partial^2 f(x)}{\partial x_1^2} & \frac{\partial^2 f(x)}{\partial x_2\partial x_1} & \cdots & \frac{\partial^2 f(x)}{\partial x_n\partial x_1}\\ \frac{\partial^2 f(x)}{\partial x_1\partial x_2} & \frac{\partial^2 f(x)}{\partial x_2^2} & \cdots & \frac{\partial^2 f(x)}{\partial x_n\partial x_2}\\ \vdots & \vdots & & \vdots\\ \frac{\partial^2 f(x)}{\partial x_1\partial x_n} & \frac{\partial^2 f(x)}{\partial x_2\partial x_n} & \cdots & \frac{\partial^2 f(x)}{\partial x_n^2}\end{bmatrix}$$

当$f(x)$的所有二阶偏导数连续时，即$\frac{\partial^2 f(x)}{\partial x_i\partial x_j}=\frac{\partial^2 f(x)}{\partial x_j\partial x_i}$，Hessian矩阵是对称的.

梯度与Hessian矩阵

常用的梯度公式

（1） $f(x)=C$(常数)，则$\nabla f(x)=0$，即$\nabla C=0$

（2） $f(x)=b^Tx$，则$\nabla f(x)=b$

（3） $f(x)=x^Tx$，则$\nabla f(x)=2x$

（4）A对称矩阵，$f(x)=x^TAx$则$\nabla f(x)=2Ax$

常用的Hessian公式

（1）$f(x)=b^Tx\Rightarrow\nabla f(x)=b,\nabla^2 f(x)=0$

（2）$f(x)=\frac{1}{2}x^Tx\Rightarrow\nabla f(x)=x,\nabla^2 f(x)=I$(单位阵)

（3）$f(x)=\frac{1}{2}x^TAx$，A对称 $\Rightarrow\nabla f(x)=Ax,\nabla^2 f(x)=A$

02 | 无约束最优性条件

最优性条件—无约束

无约束最优化问题：

$$\min\quad f(x),\qquad x\in R^n$$

其中$f(x)$是定义在R^n上的实值函数，有一阶连续偏导数

解析方法：利用函数的解析性质——驻点(梯度为零的点)，得到**最优解**。

(**一阶必要条件**)设f在点$x^*\in R^n$可微，若x^*是$\min f(x)$的局部最优解，则

$$g^*=\nabla f(x^*)=0$$

最优性条件—无约束

定理（一阶充要条件）：假设$f(x):R^n\to R$是可微的**凸函数**，则x^*是无约束最优化问题的全局最小点当且仅当$\nabla f(x^*)=0$.

(**二阶充分必要条件**)设f在点$x^*\in R^n$处的Hessian矩阵$\nabla^2 f(x^*)$存在，

- 必要条件：若x^*是f的一个局部极小点，则$\nabla f(x^*)=0$且$\nabla^2 f(x^*)$是半正定的
- 充分条件：若$\nabla f(x^*)=0$，并且$\nabla^2 f(x^*)\succ 0$正定 则x^*是$\min f(x)$的严格局部最优解。

最优性条件—无约束

利用极值条件解下列问题

$$\min f(x)=(x_1^2-1)^2+x_1^2+x_1^2-2x_1$$

解：先求驻点，由于

$$\frac{\partial f}{\partial x_1}=4x_1^3-2x_1-2,\quad\frac{\partial f}{\partial x_2}=2x_2$$

令$\nabla f(x)=0$，即$4x_1^3-2x_1-2=0$，$2x_2=0$

解得驻点$x^*=(1,0)'$

又Hessian阵$\nabla^2 f(x)=\begin{bmatrix}12x_1^2-2 & 0\\0 & 2\end{bmatrix}\Rightarrow\nabla^2 f(x^*)=\begin{bmatrix}10 & 0\\0 & 2\end{bmatrix}$正定，故

$x^*=(1,0)'$是局部极小点。

最优性条件—无约束

利用极值条件解下列问题

$$\min f(x)=\frac{1}{3}x_1^3+\frac{1}{3}x_2^3-x_2^2-x_1$$

解：先求驻点，由于

$$\frac{\partial f}{\partial x_1}=x_1^2-1,\quad \frac{\partial f}{\partial x_2}=x_2^2-2x_2$$

令$\nabla f(x)=0$，即$x_1^2-1=0,\ x_2^2-2x_2=0$

解得驻点$x^1=\begin{bmatrix}1\\0\end{bmatrix},\ x^2=\begin{bmatrix}1\\2\end{bmatrix},\ x^3=\begin{bmatrix}-1\\0\end{bmatrix},\ x^4=\begin{bmatrix}-1\\2\end{bmatrix}$

最优性条件—无约束

Hessian阵$\nabla^2 f(x)=\begin{bmatrix}2x_1 & 0\\ 0 & 2x_2-2\end{bmatrix}\Rightarrow$

$\nabla^2 f(x^1)=\begin{bmatrix}2 & 0\\ 0 & -2\end{bmatrix},\ \nabla^2 f(x^2)=\begin{bmatrix}2 & 0\\ 0 & 2\end{bmatrix},$

$\nabla^2 f(x^3)=\begin{bmatrix}-2 & 0\\ 0 & -2\end{bmatrix},\nabla^2 f(x^4)=\begin{bmatrix}-2 & 0\\ 0 & 2\end{bmatrix}$

由于$\nabla^2 f(x^1)$，$\nabla^2 f(x^3)$，$\nabla^2 f(x^4)$不定或负定，仅$\nabla^2 f(x^2)$正定，故

$x^2=\begin{bmatrix}1\\2\end{bmatrix}$是局部极小点。

算法求解

线性最小二乘：

$$\min_{x\in R^n} f(x)\triangleq\frac{1}{2}||b-Ax||_2^2$$

其中$A\in R^{m*n}, b\in R^m$由f可微且凸，知
x^*为一个全局最优解$\leftrightarrow\nabla f(x^*)=A^T(Ax^*-b)=0.$

非线性最小二乘(实数情形的相位恢复)：

$$\min_{x\in R^n} f(x)\triangleq\sum_{i=1}^{m} r_i^2(x),$$

其中$r_i(x)=(a_i^T x)^2-b_i^2, i=1,2,\ldots,m.$

最小二乘法

曲线拟合：信号处理、物理实验数据分析

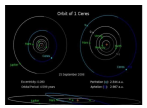
如通过观测数据拟合行星轨道曲线，从而预测行星的位置和运动轨迹

图像配准：医学成像、计算机视觉

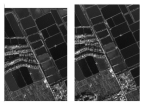
如在影像匹配中，将不同时间点拍摄的扫描图像进行对齐，以便进行详细比较。

信号去噪：语音处理、图像处理

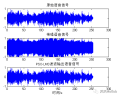
如在语音处理系统中，利用最小二乘法从录音中去除背景噪声，提升语音识别系统的准确率。



高斯，最小二乘法，行星轨道



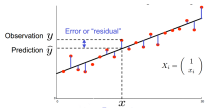
最小二乘影像匹配



恢复原始信号

最小二乘法—数据拟合

最小二乘法是一种数学优化技术，它通过最小化误差的平方和来寻找数据的最佳函数匹配。这种方法常用于数据拟合。



线性回归

$$h_\theta(x)=\sum_{i=1}^{n}\theta_i x_i=\theta^{\mathrm{T}}x$$

$$J_l(\theta)=\frac{1}{2}\sum_{i=1}^{n}(h_\theta(x^{(i)})-y^{(i)})^2=\frac{1}{2}(X\theta-y)^{\mathrm{T}}(X\theta-y)$$

$$\nabla_\theta J(\theta)=\nabla_\theta\frac{1}{2}(X\theta-y)^{\mathrm{T}}(X\theta-y)=\frac{1}{2}\nabla_\theta(\theta^{\mathrm{T}}X^{\mathrm{T}}X\theta-\theta^{\mathrm{T}}X^{\mathrm{T}}y-y^{\mathrm{T}}X\theta+y^{\mathrm{T}}y)$$

$$=\frac{1}{2}\nabla_\theta(\mathrm{tr}\theta^{\mathrm{T}}X^{\mathrm{T}}X\theta-2\mathrm{try}^{\mathrm{T}}X\theta)=X^{\mathrm{T}}X\theta-X^{\mathrm{T}}y$$

$\theta^*=(X^{\mathrm{T}}X)^{-1}X^{\mathrm{T}}y$ ⇒ 在解非线性规划时，最常见的是**迭代下降算法**

迭代下降算法基本流程

定义：算法收敛、迭代下降算法

一般迭代算法：

（1）初始点x^0

（2）按照某种搜索方向d^k产生下一个迭代点$x^{k+1}=x^k+\lambda_k d^k.$

（i）如果点列$\{x^k\}$收敛于最优解x^*，则称此算法收敛

（ii）如果$f(x^0)>f(x^1)>\cdots>f(x^k)>\cdots$，则称此算法为迭代下降算法。

迭代算法终止条件

常用的收敛性判别准则(终止条件):

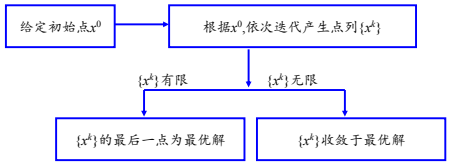
① $\|x^{k+1}-x^k\|<\varepsilon_1$

② $|f(x^{k+1})-f(x^k)|<\varepsilon_2$

③ $\dfrac{\|x^{k+1}-x^k\|}{\|x^k\|}<\varepsilon_3\quad(\|x^k\|>\varepsilon)$

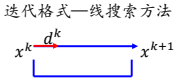
④ $\dfrac{|f(x^{k+1})-f(x^k)|}{|f(x^k)|}<\varepsilon_4\quad(|f(x^k)|>\varepsilon)$

迭代求解



线搜索

迭代格式—线搜索方法



$$x^{k+1}-x^k=\Delta x^k$$

$$\Delta x^k=\lambda_k d^k$$

$$x^{k+1}=x^k+\Delta x^k=x^k+\lambda_k d^k$$

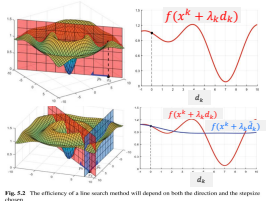


Fig. 5.2 The efficiency of a line search method will depend on both the direction and the stepsize chosen

称d^k为第k轮**搜索方向**，λ_k为第k轮沿d^k方向的**步长**

线搜索类算法的关键是如何选取一个好的方向d^k以及合适的步长λ_k

步长线搜索

- 固定步长λ
- 步长线搜索的目标是选取合适的λ_k使得$f(x^k+\lambda d^k)$尽可能减小，即选取λ_k应该使得f充分下降，与此同时不应在寻找λ_k上花费过多的计算量．一个自然的想法是寻找λ_k使得

$$\lambda_k = argmin_{\lambda>0}\ \emptyset(\lambda) = f(x^k+\lambda d^k)$$

- 精确线搜索算法：λ_k为最优步长
- 线搜索

线搜索准则

1. 函数值$f(x)$充分下降 $f(x^k+\lambda_k d^k) < f(x^k)$;
2. x^{k+1}与x^k之间有足够距离.

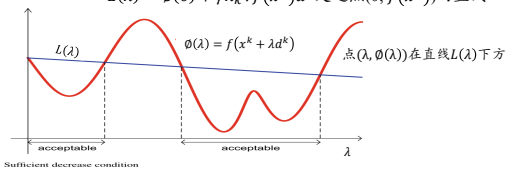
步长线搜索算法

Armijo准则：设d^k是点x^k处的搜索方向（通常为下降方向，满足$\nabla f(x^k)d^k < 0$），对于$\gamma \in (0,1)$，λ_k满足

$$f(x^k+\lambda_k d^k) \le f(x^k) + \gamma\lambda_k \nabla f(x^k)d^k$$

函数值$f(x)$充分下降

$L(\lambda) = \emptyset(0) + \gamma\lambda_k\nabla f(x^k)d^k$是过点$(0, f(x^k))$的直线



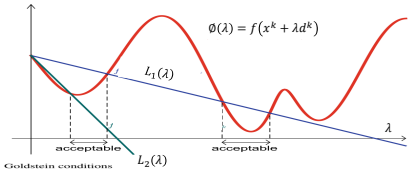
步长线搜索算法

Goldstein 准则:设d^k是点x^k处的下降方向，给定$c \in (0,1/2)$，λ_k满足

$$f(x^k+\lambda_k d^k) \le f(x^k) + \lambda_k c\nabla f(x^k)d^k = L_1(\lambda)\ （上界）$$
$$f(x^k+\lambda_k d^k) \ge f(x^k) + \lambda_k (1-c)\nabla f(x^k)d^k = L_2(\lambda)\ （下界）$$

函数值$f(x)$充分下降

x^{k+1}与x^k之间有足够距离



步长线搜索算法

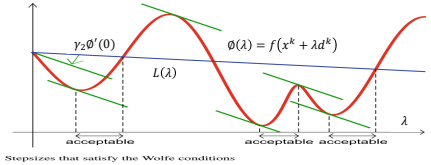
Wolfe准则：设d^k是点x^k处的下降方向，对于$\gamma_1, \gamma_2 \in (0,1)$，且$\gamma_1 < \gamma_2$，$\lambda_k$满足

$$f(x^k+\lambda_k d^k) \le f(x^k) + \gamma_1\lambda_k\nabla f(x^k)d^k$$
$$\nabla f(x^k+\lambda_k d^k)d^k \ge \gamma_2 \nabla f(x^k)d^k$$

函数值$f(x)$充分下降

Rejects too negative slopes.

x^{k+1}与x^k之间有足够距离



步长线搜索算法

线搜索回退法：Backtracking

从较大的给定初值步长$\hat{\lambda}$出发，通过不断以指数方式缩小试探步长，找到第一个满足 Armijo准则的点.

算法： 线搜索回退法

1: 选择初始步长 $\hat{\lambda}$, 参数 $\gamma, c \in (0,1)$. 初始化 $\lambda \leftarrow \hat{\lambda}$.

2: while $f(x^k+\lambda d^k) > f(x^k) + \gamma\lambda\nabla f(x^k)^T d^k$ do

3: 令 $\lambda \leftarrow c\lambda$

4: end while

5: 输出 $\lambda_k = \lambda$

03 | 使用导数的最优化方法

使用导数的最优化方法

- 最速下降法
- 牛顿法
- 拟牛顿法

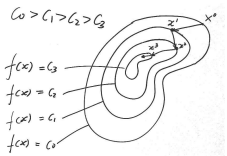
下降方向

定义： 特殊搜索方向——**下降方向**

设$f(x)$在点x^*处可微: $R^n \to R^1, x \in R^n$, 若存在方向d, 使得$\nabla f(x)^T d < 0$, 则存在$\delta > 0$, 使得对任意$\lambda \in (0,\delta)$, 有

$$f(x+\lambda d) < f(x), \qquad \forall \lambda \in (0,\delta)$$

则称向量d是函数$f(x)$在点x处的下降方向。



最速下降法

考虑无约束问题

$$\min f(x), x \in R^n$$

其中 $f(x)$具有一阶连续偏导数。

最速下降法： 一般策略是希望从某一点出发，选择一个目标函数值下降最快的方向，沿此方向搜索以期尽快达到极小点。

定理: 设$f: R^n \to R$在点$x \in R^n$处可微，若存在$d \in R^n$,使

$$\nabla f(x)^T d < 0$$

则向量d是f在x点处的下降方向，其中$-\nabla f(x)$是下降速度最快的方向。

最速下降法

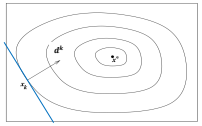
函数$f(x)$在点x处沿方向d的变化率可用方向导数表示，当函数可微时有

方向导数:

$$Df(x,d)=\nabla f(x)^T d$$

因此，单位最速下降方向d是如下问题的解：

$$\min_{d} \quad d^T\nabla f_k,$$
$$s.t.\ ||d||=1$$



由于$d^T\nabla f_k=||d||\,||\nabla f_k||cos\theta=||\nabla f_k||cos\theta \quad ||d||=1$

$cos\theta$取最小值-1，$\theta=\pi$

因此：$d=-\nabla f_k/||\nabla f_k||$在点$x$处沿$d$所定义的方向变化率最大，即负梯度方向为最速下降方向.

最速下降法

最速下降算法迭代公式为

$$x^{k+1}=x^k+\lambda_k d^k$$

其中d^k是从x^k出发的搜索方向，此处取在点x^k的最速下降方向，即

$$d^k=-\nabla f(x^k)$$

λ_k是从x^k出发沿方向d^k进行一维搜索的步长，即满足

$$f(x^k+\lambda_k d^k)=\min_{\lambda\geq 0} f(x^k+\lambda d^k)$$

步长λ_k的选取可依赖于线搜索算法，也可直接选取固定的λ_k

最速下降法

算法描述

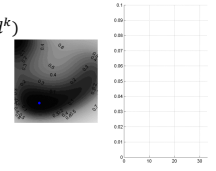
Step1:给定初始点$x^k\in R^n$,允许误差$\varepsilon>0$,置$k=1$

Step2:计算搜索方向$d^k=-\nabla f(x^k)$

Step3:若$||d^k||\leq\varepsilon$停止,否则,从x^k出发,沿d^k进行一维搜索求λ_k,使得

$$f(x^k+\lambda_k d^k)=\min_{\lambda\geq 0} f(x^k+\lambda d^k)$$

Step4:令$x^{k+1}=x^k+\lambda_k d^k$,置$k:=k+1$,转 Step2



最速下降法

用最速下降法求解下列问题

$$\min \quad f(x)=2x_1^2+x_2^2 \qquad 初点x^1=(1,1)^T,\varepsilon=\frac{1}{10}$$

第1次迭代

$$\nabla f(x^1)=\begin{bmatrix}4x_1\\2x_2\end{bmatrix} \Rightarrow \quad d^1=-\nabla f(x^1)=\begin{bmatrix}-4\\-2\end{bmatrix} \quad ||d||=2\sqrt{5}>1/10$$

从x^1出发,沿方向d^1进行一维搜索,求步长λ_1,即

$$\min_{\lambda\geq 0}\varphi(\lambda)\overset{记}{=}f(x^1+\lambda d^1)$$

$$x^1+\lambda d^1=\begin{bmatrix}1\\1\end{bmatrix}+\lambda\begin{bmatrix}-4\\-2\end{bmatrix}=\begin{bmatrix}1-4\lambda\\1-2\lambda\end{bmatrix} \qquad \varphi(\lambda)=2(1-4\lambda)^2+(1-2\lambda)^2$$

$$\varphi'(\lambda)=-16(1-4\lambda)-4(1-2\lambda)=0\Rightarrow \quad \lambda_1=5/18$$

最速下降法

在直线上的极小点 $x^2=x^1+\lambda_1 d^1=\begin{bmatrix}-1/9\\4/9\end{bmatrix}$

第2次迭代 $d^2=-\nabla f(x^2)=\begin{bmatrix}4/9\\-8/9\end{bmatrix}$

从x^2出发,沿方向d^2进行一维搜索:

$$\min_{\lambda\geq 0}\varphi(\lambda)\overset{记}{=}f(x^2+\lambda d^2)$$

$$\varphi(\lambda)=\frac{2}{81}(-1+4\lambda)^2+\frac{16}{81}(1-2\lambda)^2$$

$$\varphi'(\lambda)=\frac{16}{81}(-1+4\lambda)-\frac{64}{81}(1-2\lambda)=0\Rightarrow \quad \lambda_2=5/12$$

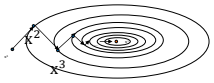
$x^3=x^2+\lambda_2 d^2=\frac{2}{27}\begin{bmatrix}1\\1\end{bmatrix}$ ➡ $x^4=x^3+\lambda_2 d^3=\frac{2}{243}\begin{bmatrix}-1\\4\end{bmatrix}$ ➡ $\bar{x}=\frac{2}{243}\begin{bmatrix}-1\\4\end{bmatrix}$ ➡问题的最优解为$x^*=(0,0)$

最速下降法

算法的收敛性

结论: 最速下降法产生的序列$\{x^k\}$是线性收敛的

特点:线性收敛，易产生扭摆现象而造成早停。当x^k距最优点x^*较远时，速度快，而接近最优点时，速度下降。



最速下降法的锯齿现象

牛顿法

基本思想：设$f(x)$是二次可微函数，为了由x^k产生x^{k+1}，在x^k附近用二次函数$\phi(x)$近似$f(x)$，设x^k是$f(x)$的极小点的一个估计,在x^k点泰勒展开式:

$$f(x)\approx\phi(x)$$
$$=f(x^k)+\nabla f(x^k)^T(x-x^k)+\frac{1}{2}(x-x^k)^T\nabla^2 f(x^k)(x-x^k)$$

其中$\nabla^2 f(x^k)$是$f(x)$在点x^k处的Hessian矩阵。

两边对x求导,则$\nabla\phi(x)=\nabla f(x^k)+\nabla^2 f(x^k)(x-x^k)=0$

牛顿法

- 设$\nabla^2 f(x^k)$可逆,则得牛顿法的迭代公式:

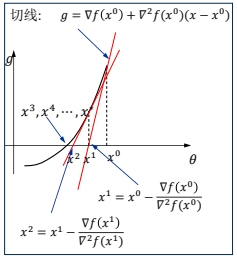
$$x^{k+1}=x^k-\nabla^2 f(x^k)^{-1}\nabla f(x^k)$$

算法(牛顿法)

Step1：给定初始点x^0,允许误差$\varepsilon>0$,置$k=1$;

Step2：若$\|\nabla f(x^k)\|\leq\varepsilon$,停止,得解$x^k$;否则,令$x^{k+1}=x^k-\nabla^2 f(x^k)^{-1}\nabla f(x^k)$,

Step3：$k:=k+1$,转Step2

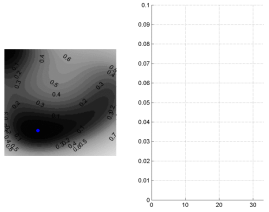


牛顿法

先用极值条件求解. 令

$$\nabla f(x)=Ax+b=0$$

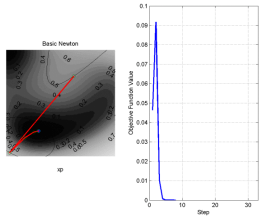
得最优解 $\bar{x}=-A^{-1}b$



用牛顿法解, 任取一初始点x^1

$$x^2=x^1-A^{-1}(Ax^1+b)=-A^{-1}b$$

显然,$x^2=\bar{x}$.即一次迭代即达极小点.



牛顿法

- 收敛速度快，为二阶收敛。$\nabla^2 f(x^*)$需正定，半正定条件下可能退化到Q-线性收敛，

$$\frac{||x^{k+1}-x^*||}{||x^k-x^*||^2}<\lambda, \lambda>0.$$

- 初始点要选在最优点附近，因为局部收敛性。应用时常以梯度类算法先求得较低精度的解，后用牛顿法加速.
- 对比与最速下降法：算法在有限次迭代后可到达函数的极小值点，称此算法具有二次终止性

牛顿法

例 用牛顿法求解下列问题

$$\min\ (x_1-1)^4+x_2^2 \quad \text{取初点} x^1=(0,1)'$$

第1次迭代

$$\nabla f(x^1)=\begin{bmatrix}4(x_1-1)^3\\2x_2\end{bmatrix}=\begin{bmatrix}-4\\2\end{bmatrix}, \nabla^2 f(x^1)=\begin{bmatrix}12(x_1-1)^2&0\\0&2\end{bmatrix}=\begin{bmatrix}12&0\\0&2\end{bmatrix}$$

更新参数

$$x^2=x^1-\nabla^2 f(x^1)^{-1}\nabla f(x^1)=\begin{bmatrix}0\\1\end{bmatrix}-\begin{bmatrix}12&0\\0&2\end{bmatrix}^{-1}\begin{bmatrix}-4\\2\end{bmatrix}=\begin{bmatrix}1/3\\0\end{bmatrix}$$

第2次迭代

$$\nabla f(x^2)=\begin{bmatrix}-32/27\\0\end{bmatrix}, \nabla^2 f(x^2)=\begin{bmatrix}48/9&0\\0&2\end{bmatrix} \quad x^3=x^2-\nabla^2 f(x^2)^{-1}\nabla f(x^2)=\begin{bmatrix}5/9\\0\end{bmatrix}$$

牛顿法

第3次迭代

$$\nabla f(x^3)=\begin{bmatrix}-256/729\\0\end{bmatrix}, \nabla^2 f(x^3)=\begin{bmatrix}64/27&0\\0&2\end{bmatrix}$$

$$x^4=x^3-\nabla^2 f(x^3)^{-1}\nabla f(x^3)$$

$$=\begin{bmatrix}5/9\\0\end{bmatrix}-\begin{bmatrix}64/27&0\\0&2\end{bmatrix}^{-1}\begin{bmatrix}-256/729\\0\end{bmatrix}=\begin{bmatrix}19/27\\0\end{bmatrix}$$

继续下去，第4次迭代，…得到点列收敛于$(1,0)$，此为最优解。

牛顿法

问题一： 如何使得 $f(x^{k+1})<f(x^k)$ ？

因为 $x^{k+1}=x^k-\nabla^2 f(x^k)^{-1}\nabla f(x^k)=x^k+d^k$ $\qquad x^{k+1}=x^k+\lambda_k d^k$

当$\nabla^2 f(x^k)>0$ 时， 有：

$\nabla f(x^k)^T d^k=-\nabla f(x^k)^T\nabla^2 f(x^k)^{-1}\nabla f(x^k)<0,$

所以 当$\nabla^2 f(x^k)>0$ 时， d^k是下降方向。

如果对牛顿法稍作修正：

$x^{k+1}=x^k+\lambda_k d^k$

$f(x^k+\lambda_k d^k)=\min_{\lambda} f(x^k+\lambda d^k)$ ➡ 则有：$f(x^{k+1})<f(x^k)$

牛顿法

问题二： G_k^{-1}的存在性和计算量问题 ？

$$x^{k+1}=x^k-G_k^{-1}\nabla f(x^k)$$

1. 用正定矩阵H_k替代G_k^{-1}， $x^{k+1}=x^k-H_k\nabla f(x^k)$

2. 考虑更一般的形式： $x^{k+1}=x^k-\lambda_k H_k\nabla f(x^k)$

牛顿法

解决$Hessian$矩阵$\nabla^2 f(x^k)$非正定问题的基本思想

修正$\nabla^2 f(x^k)$，构造一个对称正定矩阵G_k，用G_k取代矩阵$\nabla^2 f(x^k)$：

$$G_k d^k=-\nabla f(x^k) \quad \Rightarrow d^k=-G_k^{-1}\nabla f(x^k)$$

再沿此方向作一维搜索，迭代更新…

问题：如何构造G_k?

比如，可令

$$G_k=\nabla^2 f(x^k)+\varepsilon_k I$$

其中I是单位阵，ε_k是一个适当的正数。

修正牛顿法

Step1：给定初始点x^0，允许误差$\varepsilon>0$，置$k=0$;

Step2：计算梯度$g^k=\nabla f(x^k)$，若$\|\nabla f(x^k)\|\le\varepsilon$，停止，得解$x^k$;

否则转Step3

Step3：计算矩阵$G_k=\nabla^2 f(x^k)$，置矩阵$B_k=G_k+E_k$，其中E_k为修正矩阵

(当G_k正定时，它取0)，计算修正牛顿方向

$$d^k=-(B_k)^{-1}\nabla f(x^k)$$

Step4：从x^k出发，沿方向d^k作一维搜索：

$$\min_{\lambda} f(x^k+\lambda d^k)=f(x^k+\lambda_k d^k)$$

令 $x^{k+1}=x^k+\lambda_k d^k$，置$k:=k+1$，转Step2

拟牛顿法

基本思想

牛顿法成功的关键在于利用了负梯度信息与Hessian矩阵提供的曲率信息，但计算Hessian矩阵工作量大，并且有时Hessian矩阵很难计算，甚至不好求出.

拟牛顿法就是利用目标函数值和一阶导数的信息，构造出目标函数的曲率近似，使用常数矩阵近似替代Hessian矩阵，不用求偏导与求逆，简化运算，同时具有收敛速度快的优点。

拟牛顿法

$$x^{k+1}=x^k-\lambda_k H_k\nabla f(x^k)$$

$H_k\equiv I$时 ⇒ 梯度法，

最速下降方向 $d^k=-\nabla f(x^k)$， 度量为$\|d\|=\sqrt{d^T I d}$

$H_k=G_k^{-1}$时 ⇒ 牛顿法

最速下降方向 $d^k=-G_k^{-1}\nabla f(x^k)$， 度量为$\|d\|=\sqrt{d^T G_k^{-1} d}$

也称拟牛顿法为变尺度算法.

拟牛顿法

问题三：H_k需要满足条件：

(1)迭代公式具有下降性质 $\Rightarrow H_k > 0$

(2)H_k的计算量要小 $\Rightarrow H_{k+1} = H_k + \Delta H_k$

(3)收敛速度要快 $\Rightarrow H_k \approx G_k^{-1}$

如何保证 $H_k > 0$和$H_k \approx G_k^{-1}$?

如何确定 ΔH_k?

拟牛顿法

- 构造近似矩阵H_k：分析G_k^{-1}需满足的条件，并利用此条件确定H_k

在第k次迭代，$f(x^k)$在点x^{k+1}的泰勒展开如下：

$$f(x^k) \approx f(x^{k+1}) + \nabla f(x^{k+1})^T(x^k - x^{k+1}) + \frac{1}{2}(x^k - x^{k+1})^T\nabla^2 f(x^{k+1})(x^k - x^{k+1})$$

$$\Downarrow$$

$$\nabla f(x^k) \approx \nabla f(x^{k+1}) + \nabla^2 f(x^{k+1})(x^k - x^{k+1})$$

记 $\Delta x_k = x^{k+1} - x^k$，$\Delta g_k = \nabla f(x^{k+1}) - \nabla f(x^k)$ $\Rightarrow$ 则 $\Delta g_k \approx \nabla^2 f(x^{k+1})\Delta x_k$

拟牛顿法

令H_{k+1}近似（取代）牛顿法中的Hessian阵的逆$\nabla^2 f(x^{k+1})^{-1}$，则H_{k+1}满足

$$H_{k+1}\Delta g_k = \Delta x^k$$

称为拟牛顿条件(方程)，也称为割线方程.

Step1(初始化)：给定初始点$x^0 \in R^n$，正定矩阵$H_0 \in R^{n\times n}$，$\varepsilon \in (0,1)$；
计算$g^0 = \nabla f(x^0)$，置$k = 0$.

Step2(平稳性检验)：若$\|g^k\| \le \varepsilon$，则停止，否则，计算$d^k = -H_k g^k$，

Step3(线搜索)：$\min_{\lambda} f(x^k + \lambda d^k)$，求出$\lambda_k$，令$x^{k+1} = x^k + \lambda_k d^k$

Step4(修正拟牛顿方程)：计算$g^{k+1} = \nabla f(x^{k+1})$，对$H_k$校正，使得$H_{k+1}$满足拟牛顿条件，令k ← k+1，转Step2

拟牛顿法

怎样确定满足这个条件的H_{k+1}？ – 秩1校正法

$H_{k+1}\Delta g_k = \Delta x^k$，$H_{k+1} = H_k + \Delta H_k$ 定义 $\Rightarrow$ $\Delta H_k = \alpha_k z_k z_k^T$ 推出 $\Rightarrow$ $H_{k+1} = H_k + \frac{(\Delta x^k - H_k\Delta g_k)(\Delta x^k - H_k\Delta g_k)^T}{\Delta g_k^T(\Delta x^k - H_k\Delta g_k)}$

待定：$\alpha_k \in R$，$z_k \in R^n$

$\Delta x^k = (H_k + \Delta H_k)\Delta g_k$ 求得z_k $\quad z_k = \frac{\Delta x_k - H_k\Delta g_k}{\alpha_k z_k^T\Delta g_k}$

$\Delta g_k{}^T\Delta x^k = \Delta g_k{}^T(H_k + \Delta H_k)\Delta g_k$

$\Delta g_k{}^T(\Delta x^k - H_k\Delta g_k) = \Delta g_k{}^T\Delta H_k\Delta g_k$ $\quad \Delta g_k{}^T(\Delta x^k - H_k\Delta g_k) = \alpha_k\Delta g_k{}^T z_k z_k^T\Delta g_k$

拟牛顿法

怎样确定满足这个条件的H_{k+1}？ – 秩2校正法

$H_{k+1} = H_k + \Delta H_k$

$= H_k + \alpha_k u_k u_k^T + \beta_k v_k v_k^T$ 待定：α_k，$\beta_k \in R$，u_k，$v_k \in R^n$

根据拟牛顿条件：$H_{k+1}\Delta g_k = \Delta x_k$，得

$(H_k + \alpha_k u_k u_k^T + \beta_k v_k v_k^T)\Delta g_k = \Delta x_k$

即：$\alpha_k u_k u_k^T + \beta_k v_k v_k^T)\Delta g_k = \Delta x_k - H_k$

满足上述方程的解很多，可以如下确定一组解

$\alpha_k u_k u_k^T\Delta g_k = \Delta x_k$ $\quad \beta_k v_k v_k^T\Delta g_k = -H_k\Delta g_k$

拟牛顿法

$\alpha_k u_k u_k^T\Delta g_k = \Delta x_k$ $\quad \beta_k v_k v_k^T\Delta g_k = -H_k\Delta g_k$

可以取：

$u_k = \Delta x_k$，$\alpha_k u_k^T\Delta g_k = 1$，$\Rightarrow$ $\alpha_k = \frac{1}{\Delta x_k^T\Delta g_k}$

$v_k = H_k\Delta g_k$，$\beta_k v_k^T\Delta g_k = -1$，$\beta_k = -\frac{1}{\Delta g_k^T H_k\Delta g_k}$

根据上述推导，得到H_k的定义DFP的校正公式:

$$H_{k+1} = H_k + \frac{\Delta x_k^T\Delta x_k}{\Delta x_k^T\Delta g_k} - \frac{H_k\Delta g_k\Delta g_k^T H_k}{\Delta g_k^T H_k\Delta g_k}$$ – DFP校正公式

性质： $H_0 > 0 \Rightarrow H_k > 0$。

DFP算法

Step1：给定初始点$x^k \in R^n$，允许误差$\varepsilon > 0$，

Step2：置$k = 1$，$H_1 = I_n$，计算出在x^1处的梯度

$$g_1 = \nabla f(x^1)$$

Step3：令 $d^k = -H_k g_k$

Step4：从x^k出发，沿d^k进行一维搜索，求λ_k，使

$$f(x^k + \lambda_k d^k) = \min_{\lambda\ge 0} f(x^k + \lambda d^k)$$

令$x^{k+1} = x^k + \lambda_k d^k$，

DFP算法

Step5：检验是否满足收敛准则，若

$$\|\nabla f(x^{k+1})\| \le \varepsilon,$$

停止，得$\bar{x} = x^{k+1}$，否则，转Step6

Step6：若$k = n$，则令$x^1 = x^{k+1}$，转Step2；否则，转Step7

Step7：令$g_{k+1} = \nabla f(x^{k+1})$，$\Delta x_k = x^{k+1} - x^k$，$\Delta g_k = g_{k+1} - g_k$，
计算H_{k+1}，置$k := k + 1$，转Step3

拟牛顿法

用DFP方法求解下列问题

$$\min \quad 2x_1^2 + x_2^2 - 4x_1 + 2$$

初始点及初始矩阵分别为 $x^1 = \begin{pmatrix}2\\1\end{pmatrix}$，$H_1 = \begin{pmatrix}1 & 0\\0 & 1\end{pmatrix}$

第1次迭代，点x^1梯度与搜索方向

$$g = \begin{pmatrix}4(x_1 - 1)\\2x_2\end{pmatrix} = \begin{pmatrix}4\\2\end{pmatrix} \quad d^1 = -H_1 g_1 = \begin{pmatrix}-4\\-2\end{pmatrix}$$

从x^1出发，沿方向d^1进行一维搜索，求步长λ_1:

$$\min_{\lambda\ge 0} f(x^1 + \lambda d^1)$$

得到 $\lambda_1 = \frac{5}{18}$

拟牛顿法

$x^2 = x^1 + \lambda_1 d^1 = \begin{bmatrix}2\\1\end{bmatrix} + \frac{5}{18}\begin{bmatrix}-4\\-2\end{bmatrix} = \begin{bmatrix}8/9\\4/9\end{bmatrix}$ $\quad g_2 = \begin{bmatrix}4(\frac{8}{9}-1\\2\frac{4}{9}\end{bmatrix} = \begin{bmatrix}-4/9\\8/9\end{bmatrix}$

第2次迭代，计算$\Delta x_1, \Delta g_1, H_2$与$d^2$

$$\Delta x_1 = \lambda_1 d^1 = \begin{pmatrix}-10/9\\-5/9\end{pmatrix},\ \Delta g_1 = g_2 - g_1 = \begin{pmatrix}-40/9\\-10/9\end{pmatrix},$$

$H_2 = H_1 + \frac{\Delta x_1 \Delta x_1^T}{\Delta x_1^T \Delta g_1} - \frac{H_1 \Delta g_1 \Delta g_1^T H_1}{\Delta g_1^T H_1 \Delta g_1} = \frac{1}{306}\begin{pmatrix}86 & -38\\-38 & 305\end{pmatrix}$ $\quad d^2 = -H_2 g_2 = \frac{12}{51}\begin{pmatrix}1\\-4\end{pmatrix}$

从x^2出发，沿方向d^2进行一维搜索，求步长λ_2:

$$\min_{\lambda \geq 0} f(x^1 + \lambda d^1) \qquad \lambda_2 = \frac{17}{36}$$

$x^3 = x^2 + \lambda_2 d^2 = \begin{bmatrix}1\\0\end{bmatrix}$ ➡ $g_3 = \nabla f(x^3) = \begin{bmatrix}0\\0\end{bmatrix}$ ➡ 最优解：$(x_1, x_2) = (1,0)$

拟牛顿法

变尺度算法的校正公式

一般的变尺度算法主要是**Huang**族公式：

$$H_{k+1} = H_k + \Delta x_k u_k^T + H_k \Delta g_k v_k^T$$

其中：

$$u_k = a_k \Delta x_k + b_k H_k^T \Delta g_k$$

$$v_k = c_k \Delta x_k + d_k H_k^T \Delta g_k$$

且满足：

$$u_k^T \Delta g_k = \omega \qquad v_k^T \Delta g_k = -1$$

这个公式含有5个参数 $(a_k, b_k, c_k, d_k, \omega)$

拟牛顿法

较重要的三种公式是：

(i) 令 $\omega = 1$，$c_k = b_k = 0$，即DFP公式。

(ii) 令 $\omega = 1$，$b_k = c_k$，即Broyden族公式。

(iii) 令 $\omega = 1$，$b_k = c_k$，$d_k = 0$，即得重要的BFGS公式：

$$H_{k+1} = H_k + \frac{\beta_k \Delta x_k \Delta x_k^T - H_k \Delta g_k \Delta x_k^T - \Delta x_k \Delta g_k^T H_k}{\Delta x_k^T \Delta g_k}$$

$$\beta_k = 1 + \frac{\Delta g_k^T H_k \Delta g_k}{\Delta x_k^T \Delta g_k}$$

它是当前变度量方法中数值稳定性最好的。

常用无约束优化算法

$$x^{k+1} = x^k + \lambda_k d^k$$

1、最速下降法

搜索方向 $d^k = -\nabla f(x^k)$; 步长: $f(x^k + \lambda_k d^k) = min_\lambda f(x^k + \lambda d^k)$

2. 牛顿法

搜索方向: 当G_k可逆时, 步长: $\lambda \equiv 1$; $d^k = -G_k^{-1} g_k$, $g_k = \nabla f(x^k), G_k = \nabla^2 f(x^k)$

3. 拟牛顿法(变尺度法)

搜索方向: $d^k = -H_k \nabla f(x^k)$; 步长: $f(x^k + \lambda_k d^k) = minf(x^k + \lambda d^k)$

04 | 约束最优性条件及方法

最优性条件—有约束

约束最优化问题的形式 $\quad \min \ f(x)$

$$\text{s.t.} \begin{cases} h_i(x) = 0 & i = 1,2,\cdots,m \\ g_j(x) \geq 0 & j = 1,2,\cdots,l \end{cases}$$

记 $h(x) = (h_1(x), h_2(x), \cdots, h_m(x))^T$, $g(x) = (g_1(x), g_2(x), \cdots, g_l(x))^T$,

则约束优化问题可记为

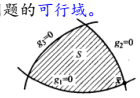
$$\min \ f(x)$$

$$\text{s.t.} \begin{cases} h(x) = 0 \\ g(x) \geq 0 \end{cases}$$

令 $S = \{x \mid h(x) = 0, g(x) \geq 0\}$，称$Q$为此约束极值问题的可行域。

（1）$I = \{i | g_i(\bar{x}) = 0\}$——在$\bar{x}$处起作用约束

（2）$g_i(\bar{x}) > 0, i \notin I$ ——在$\bar{x}$处不起作用约束



最优性条件—有约束

构造拉格朗日函数

$$L(x,u,v) = f(x) - \sum_{j=1}^{l} u_j g_j(x) - \sum_{j=1}^{m} v_j h_j(x)$$

$$= f(x) - u^T g(x) - v^T h(x)$$

其中$u = (u_1, \cdots, u_l)^T, v = (v_1, \cdots, v_m)^T$为拉格朗日乘子（Lagrange Multipliers）

原始问题等价最小最大问题：

$$\min_x \max_{u,v} L(x,u,v) = \min_x \max_{u,v} \left(f(x) - \sum_{j=1}^{l} u_j g_j(x) - \sum_{j=1}^{m} v_j h_j(x) \right)$$

$$= \begin{cases} \min\limits_x f(x) & if\ g_i(x) \geq 0, h_j(x) = 0 \\ \infty & otherwise \end{cases}$$

对偶问题

其对偶形式（对偶问题）定义如下：

$$\max_{u,v} \ \varphi(u,v)$$

$$s.t.\ u \geq 0(x)$$

其中目标函数

$$\varphi(u,v) = \inf\{f(x) - \sum_{j=1}^{l} u_j g_j(x) - \sum_{j=1}^{m} v_j h_j(x)\}$$ ➡ 拉格朗日函数$L(x,u,v)$中的x取下确界可定义**拉格朗日对偶函数**

对偶问题（拉格朗日最大最小问题）

$$\max_{u,v;u_i \geq 0} \min_x L(x,u,v)$$

对偶问题

原问题 $\quad \min_x \max_{u,v;u_i \geq 0} L(x,u,v)$

对偶问题 $\quad \max_{u,v;u_i \geq 0} \min_x L(x,u,v)$

对偶问题（最大最小）vs. 原始问题（最小最大）

弱对偶定理：

$$d^* = \max_{u,v;u_i \geq 0} \min_x L(x,u,v) \leq \min_x \max_{u,v;u_i \geq 0} L(x,u,v) = p^*$$

d^*和p^*分别是原始问题和对偶问题的最优解.

何时取等号？

对偶问题

当符合以下条件时：

- f和$-g_i$是凸函数，h_i是仿射变换(affine)；
- g_i(严格)可行：即一定存在x使得 $g_i(x)>0$

强对偶！

此时，原问题和对偶问题等价

$$\min_x \ f(x) \quad s.t.\ g_i(x)\geq 0,\ h_i(x)=0 \ = \ \min_x \max_{u,v;u_i\geq 0} L(x,u,v) \ = \ \max_{u,v;u_i\geq 0} \min_x L(x,u,v)$$

原问题　　对偶问题

SVM原始-对偶问题

SVM的优化问题

$$\min_{w,b} \ \frac{1}{2}||w||^2$$
$$s.t.\ y^{(i)}\left(w^T x^{(i)}+b\right)\geq 1, i=1,\dots,m$$

拉格朗日函数

$$L(w,b,\alpha)=\frac{1}{2}||w||^2-\sum_{i=1}^m \alpha_i y^{(i)}\left(w^T x^{(i)}+b\right)+\sum_{i=1}^m \alpha_i,\ \alpha_i\geq 0, i=1,\dots,m$$

对拉格朗日函数$L(w,b,\alpha)$中的w,b取下确界得到**拉格朗日对偶函数**$\max_\alpha \varphi(\alpha)$

SVM对偶问题

拉格朗日函数求导置零：对w,b的极小

$$\frac{\partial L(w,b,\alpha)}{\partial w}=w-\sum_{i=1}^m \alpha_i y^{(i)}x^{(i)}=0 \Rightarrow w=\sum_{i=1}^m \alpha_i y^{(i)}x^{(i)}$$
$$\frac{\partial L(w,b,\alpha)}{\partial b}=\sum_{i=1}^m \alpha_i y^{(i)}=0$$

把上述约束带回到拉格朗日函数

$$L(w,b,\alpha)=\sum_{i=1}^m \alpha_i-\frac{1}{2}\sum_{i=1}^m\sum_{j=1}^m \alpha_i\alpha_j y^{(i)}y^{(j)}\left(x^{(i)}\right)^T x^{(j)}-b\sum_{i=1}^m \alpha_i y^{(i)}$$
$$=\sum_{i=1}^m \alpha_i-\frac{1}{2}\sum_{i=1}^m\sum_{j=1}^m \alpha_i\alpha_j y^{(i)}y^{(j)}\left(x^{(i)}\right)^T x^{(j)}$$

SVM对偶问题

得到对偶问题

$$\max_\alpha \ \sum_{i=1}^m \alpha_i-\frac{1}{2}\sum_{i=1}^m\sum_{j=1}^m \alpha_i\alpha_j y^{(i)}y^{(j)}\langle x^{(i)},x^{(j)}\rangle \qquad \min_\alpha \ \frac{1}{2}\sum_{i=1}^m\sum_{j=1}^m \alpha_i\alpha_j y^{(i)}y^{(j)}\langle x^{(i)},x^{(j)}\rangle-\sum_{i=1}^m \alpha_i$$

$$s.t.\ \alpha_i\geq 0, i=1,\dots,m,\ \sum_{i=1}^m \alpha_i y^{(j)}=0 \quad \Rightarrow \quad s.t.\ \alpha_i\geq 0, i=1,\dots,m,\ \sum_{i=1}^m \alpha_i y^{(j)}=0$$

最优性条件—有约束

(Karush-Kuhn-Tucker必要条件) 设$x^*\in S$是问题的局部最优解，$f,g_i(i\in I)$在点x^*处可微，$g_i(i\notin I)$在点x^*处连续，h_j在点x^*连续可微.若

$$\{\nabla g_i(x^*),\nabla h_j(x^*)|i\in I,j=1,2,\cdots,l\}$$

线性无关. 则存在$u_i\geq 0(i\in I),v_j(j=1,2,\cdots,l)$,使得

$$\begin{cases}\nabla f(x^*)=\sum_{i=1}^l u_i\nabla g_i(x^*)+\sum_{j=1}^m v_j\nabla h_j(x^*)\\ h_j(x^*)=0, j=1,\cdots,m;\\ g_i(x^*)\geq 0,\ i=1,\cdots,l;\\ u_i g_i(x^*)=0, u_i\geq 0,\ i=1,2,\cdots,l\end{cases}$$

最优性条件—有约束

则KKT条件可以表示为

$$\nabla f(x^*)=u^T\nabla g(x^*)+v^T\nabla h(x^*) \quad \text{稳定性条件}$$
$$h(x^*)=0,\ g(x^*)\geq 0 \quad \text{原问题可行性}$$
$$u\geq 0 \quad \text{对偶可行性}$$
$$u^T g(x^*)=0, \quad \text{互补松弛条件}$$

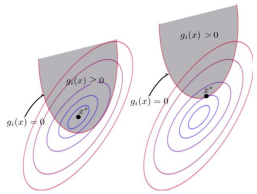
(Karush-Kuhn-Tucker充分条件)：设f为凸函数，g_i为凹函数，h_j为线性函数。对于$x^*\in S$，若f,g_i,h_j在点x^*处可微，并且KKT条件成立，则x^*为优化问题(COP)的全局极小点。

最优性条件—有约束

互补松弛条件$u^T g(x^*)=0$的含义：

假定$h(x)=0$，$l=1$，这时稳定性条件为

$$\nabla f(x^*)=u_1\nabla g_1(x^*)$$



- 当x^*为可行域的内点($g_1(x^*)>0$)时，则$\nabla f(x^*)=0$，对应的$u_1=0$；
- 当x^*为可行域的边界点($g_1(x^*)=0$)时，则$\nabla f(x^*)$与$\nabla g_1(x^*)$同方向，因此$\nabla f(x^*)=\lambda_1\nabla g_1(x^*)$，且$u_1>0$；

因此，不论是内点还是边界点，都要满足$u_1 g_1(x^*)=0$.

最优性条件—有约束

考虑下列非线性规划问题

$$\min \ x_1$$
$$s.t.\ 3(x_1-3)^2+x_2\geq 0$$
$$(x_1-3)^2+x_2^2-10=0$$

检验以下各点是否为局部最优解

$$x^1=\begin{bmatrix}2\\-3\end{bmatrix}, x^2=\begin{bmatrix}4\\-3\end{bmatrix}$$

最优性条件—有约束

记目标函数和约束函数分别为$f(x),g(x),h(x)$他们在点x处的梯度分别是

$$\nabla f(x)=\begin{Bmatrix}1\\0\end{Bmatrix}, \nabla g(x)=\begin{Bmatrix}6(x_1-3)\\1\end{Bmatrix}, \nabla h(x)=\begin{Bmatrix}2(x_1-3)\\2x_2\end{Bmatrix}$$

Lagrange函数是

$$L(x,u,v)=x_1-u[3(x_1-3)^2+x_2]-v[(x_1-3)^2+x_2^2-10]$$

检查x^1：是可行点，且两约束都是起作用约束。

$$\nabla f(x^1)=\begin{Bmatrix}1\\0\end{Bmatrix}, \nabla g(x^1)=\begin{Bmatrix}-6\\1\end{Bmatrix}, \nabla h(x^1)=\begin{Bmatrix}-2\\-6\end{Bmatrix}$$

按照KKT条件，设$\begin{Bmatrix}1\\0\end{Bmatrix}-u\begin{Bmatrix}-6\\1\end{Bmatrix}-v\begin{Bmatrix}-2\\-6\end{Bmatrix}=0\Rightarrow u=-\frac{3}{19}, v=-\frac{1}{38}$

不存在使$u\geq 0$的解，故它不是KKT点.

最优性条件—有约束

检查x^2:是可行点，且两约束都是起作用约束。

$\nabla f(x^2)=\begin{Bmatrix}1\\0\end{Bmatrix},\nabla g(x^2)=\begin{Bmatrix}6\\1\end{Bmatrix},\nabla h(x^2)=\begin{Bmatrix}2\\-6\end{Bmatrix}$

按照KKT条件，设

$\begin{Bmatrix}1\\0\end{Bmatrix}-u\begin{Bmatrix}6\\1\end{Bmatrix}-v\begin{Bmatrix}2\\-6\end{Bmatrix}=0\Rightarrow u=\frac{3}{19},v=\frac{1}{38}$

故它是KKT点

罚函数法

等式约束问题

$$\begin{aligned}\min\quad & f(x)\\ \text{s.t.}\quad & h_i(x)=0\ i=1,\cdots,m\end{aligned}$$

拉格朗日乘子法，定义辅助函数

$$F(x,\sigma)=f(x)+\sigma\sum_{i=1}^{m}h_i^2(x)$$

σ为足够大的正数

不等式约束问题

$$\begin{aligned}\min\quad & f(x)\\ \text{s.t.}\quad & g_i(x)\geq 0\ i=1,\cdots,m\end{aligned}$$

拉格朗日乘子法，定义辅助函数

$$F(x,\sigma)=f(x)+\sum_{i=1}^{m}I(g_i(x))$$

I为惩罚函数，在可行域内，惩罚函数值等于一个趋近于0的值；不在可行域内，惩罚函数值等于一个很大的正数。

罚函数法

罚函数法（SUMT）算法思想：借助罚函数，将有约束优化问题转化为一系列无约束优化问题进行求解

基本思想：通过在原始的目标函数中添加一个障碍函数（也可以理解成惩罚函数）来代替约束条件中的不等式约束。如果当前解不满足约束条件，就在目标项上加上一个正向的惩罚，强迫当前解往可行域的方向走。

迭代过程中，罚函数法通过对不可行点施加惩罚，迫使迭代点向可行域靠近。一旦迭代点成为可行点，则这个可行点就是原问题的最优解。采用不同的罚函数，就形成不同的罚方法：**外点罚函数（外点法）和内点罚函数（内点法）。**

外点法

先看不等式约束问题：

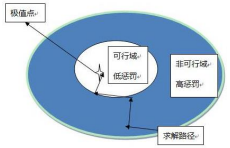
$$\begin{aligned}\min\quad & f(x)\\ \text{s.t.}\quad & g_i(x)\leq 0\ i=1,\cdots,m\end{aligned}\Leftrightarrow\quad\begin{aligned}\min\ & f(x)\\ s.t.\ & x\in D\end{aligned}$$

$D=\{x\mid g(x)\leq 0\}$: 可行域

算法思想: 构造 $\phi_k(x)$满足:

- $\phi_k(x)=f(x)\ x\in D$
- $\phi_k(x)>f(x)\ x\notin D$
- $\phi_k(x)\uparrow(k\uparrow)$, 即 $\phi_{k+1}(x)\geq\phi_k(x)$

$$x^{k+1}=\arg\min_{x\in R^n}\phi_k(x)$$



外点法

可取:$\phi_k(x)=f(x)+\lambda_k p(x)$, 其中
$p(x)$ 满足条件 : $\lambda_1<\lambda_2<\cdots<\lambda_k(\uparrow)\to+\infty$
(1) $p(x)=0\ x\in D$;
(2) $p(x)>0\ x\notin D$ 。
并取$\lambda_1<\lambda_2<\cdots<\lambda_k(\uparrow)\to+\infty$

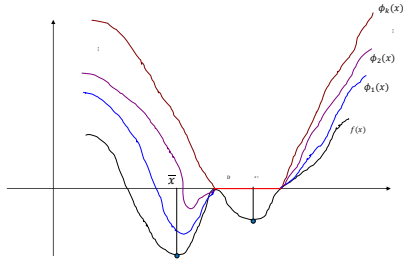
$\phi_k(x)$: 增广函数（罚函数）, $p(x)$: 惩罚项， λ_k: 惩罚因子

不等式约束： $p(x)=\sum_{j=1}^{m}\left(max\{g_j(x),0\}\right)^2$

等式约束与不等式约束： $p(x)=\sum_{j=1}^{m}\left(max\{g_j(x),0\}\right)^2+\sum_{i=1}^{n}(h_i(x))^2$

外点法

几何解释



外点法

一般约束问题:

$$\begin{aligned}\min\quad & f(x)\\ \text{s.t.}\quad & \begin{cases}g_i(x)\leq 0, i=1,\cdots,m\\ h_j(x)=0, j=1,\cdots,n\end{cases}\end{aligned}$$

构造罚函数，得其近似解:

$$min\ \ F(x,\lambda)=f(x)+\lambda p(x)$$

其中 $p(x)=\sum_{j=1}^{m}\left(max\{g_j(x),0\}\right)^2+\sum_{i=1}^{n}(h_i(x))^2$ 是连续函数，当 x 为可行点时，$p(x)$=0，从而有$F(x,\lambda)=f(x)$；当x不是可行点时，在x处，$\lambda p(x)$是很大的正数，它的存在是对点x脱离可行域的一种惩罚，其作用是在极小化过程中迫使迭代点靠近可行域

外点法

外点法步骤

Step1：给定初始点x^0,初始罚因子λ_1，放大系数c>1，允许误差$\varepsilon>0$置k=1.

Step2：以x^{k-1}为初点求解无约束问题

$$min\,\phi_k(x)=f(x)+\lambda_k p(x)$$

设其极小点为 x^k.

Step3：若$\lambda_k p(x^k)<\varepsilon$，则停止计算，得到点$x^k$；否则令$\lambda_{k+1}=c\lambda_k$，置k=k+1，返回Step2.

内点法

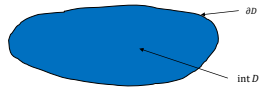
考虑不等式约束问题

$$\begin{aligned}min\quad & f(x)\\ \text{s.t. } & g_i(x)\leq 0\ i=1,\cdots,m\end{aligned}$$

$D=\{x\mid g_i(x)\leq 0, i=1,\ldots,m\}$
$=\partial D\cup int\,D=$ 边界点集 ∪内点集

$\partial D=\{x\mid$ 至少存在一个 j, 使得 $g_j(x)=0\}$

$int\ D=\{x\mid g_j(x)<0,\forall j\}$



内点法（障碍函数法）的基本思想：
是使得迭代点是在可行域点集内部移动的，对接近可行域边界上的点施加越来越大的惩罚，对可行域边界上的点施加无限大的惩罚，这好比边界是一道障碍物，阻碍迭代点穿越边界。内点法只对不等式约束的优化问题才可能有效。

内点法

主要用于求解不等式约束优化问题 $\min \quad f(x)$
s.t. $g_i(x) \le 0\ i = 1,\cdots,m$

构造函数

$\phi_k(x) = f(x) + \mu_k q(x)$,
$q(x)$ 满足：
(1) $q(x) > 0$ if $x \in \text{int } D$
(2) $q(x) \to +\infty$ if $x \to \partial D$
(3) $\mu_1 > \mu_2 > \cdots > \mu_k(\downarrow) \to 0$

$\phi_k(x)$:增广函数（罚函数）
$q(x)$:惩罚项（障碍函数）
μ_k:罚因子

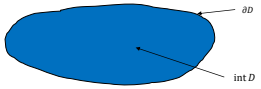
$$x^{k+1} = \arg\min_{x \in R^n} \phi_k(x),\ \ \phi_k(x) = f(x) + \mu_k q(x)$$

内点法

$q(x)$ 一般取倒数/对数形式的函数 （常取前面的惩罚项）

$q(x) = \sum_{j=1}^{m} -\frac{1}{g_j(x)}$ 或 $q(x) = \sum_{j=1}^{m} \frac{1}{g_j^2(x)}$;

$q(x) = -\sum_{j=1}^{m} ln(-g_j(x))$或 $q(x) = \sum_{j=1}^{m} ln\frac{1}{-g_j(x)}$



内点法

内点法步骤

Step1：给定初始点$x^0 \in$ int D, 允许误差$\varepsilon > 0$,初始参数μ_1，缩小系数$\beta \in (0,1)$, 置k=1.

Step2：以x^{k-1}为初点求解问题

$$\min \ \ \phi_k(x) = f(x) + u_k q(x)$$
$$\text{s.t. } x \in \text{ int } D$$

设其极小点为 x^k.

Step3：若$u_k q(x^k) < \varepsilon$，则停止计算,得到点x^k;否则,令$u_{k+1} = \beta u_k$,置k=k+1, 返回Step2.

罚函数比较

外点法	内点法
1.任意$x^0 \in R^n$	1. $x^0 \in D^0$
2.不/等式约束适用	2.等式约束不适用
3.惩罚项的二阶偏导在D的边界上不存在	3.障碍函数在D的可微阶数与$g_i(x)$ 相同
4.迭代中$x^k \notin D$	4.迭代中$x^k \in D$(随时可取$x^k \approx x^*$)
5.非凸规划适用	5.非凸规划适用

增广拉格朗日函数法

增广的拉格朗日乘子法

考虑等式约束问题 $\begin{cases} \min f(x) \\ s.t. h(x) = 0 \end{cases}$

用拉格朗日函数代替$f(x)$:

构造乘子罚函数：

$$L(x,v) = f(x) + \sum_{i=1}^{l} v_i h_i(x)$$

$$\varphi(x,v,\mu) = f(x) + \sum_{i=1}^{l} v_i h_i(x) + \sum_{i=1}^{l} \mu_i h_i^2(x)$$

其中：$v \in R^l$为乘子，$\mu \in R^l$为罚因子。

增广拉格朗日函数与拉格朗日函数的区别：惩罚的二次项。

增广拉格朗日函数法

增广拉格朗日函数法

求解 $\min \ \ \varphi(x, v^k, \mu^k)$ 得到$x^k, k = 0,1,2,\cdots$

若$h(x^k) = 0$得到解x^k及乘子v^k;

否则 调整v^k及μ^k

可以证明：存在μ'，当$\mu > \mu'$时，存在v^*, 使得$\min\ \varphi(x, v^*, \mu)$的最优解，即原问题的解。因此不需要更新$\mu$，只要取充分大。

增广拉格朗日函数法

v^k的更新,使得$v^k \to v^*$

固定v^k, μ，最小化φ函数得到新的迭代点x^{k+1}

$$\nabla_x \varphi(x^{k+1}, v^k, \mu) = \nabla f(x^{k+1}) + \sum_{j=1}^{l} (v_j^k + \mu_j h_j(x^{k+1})) \nabla h_j(x^{k+1}) = 0$$

原KKT条件 $\nabla f(x^*) + \sum_{j=1}^{l} v_j^* \nabla h_j(x^*) = 0$，$v_j^* \approx v_j^k + \mu_j h_j(x^{k+1}), j = 1,2,\ldots,l$

$$x^{k+1} \approx x^*$$

$$v_j^{k+1} = v_j^k + \mu_j h_j(x^{k+1}), j = 1,2,\ldots,l$$

$$\Rightarrow \begin{cases} x^{(k)} = \arg\min_x \ \phi(x, v^k, \mu) \\ v_j^{k+1} = v_j^k + \mu_j h_j(x^{k+1}), j = 1,2,\ldots,l \end{cases}$$

增广拉格朗日函数法

Step1:给定初始点 x^0，初始乘子向量 v^1,初始罚因子μ^1及其放大系数$\alpha > 1$(可取$2 \le \alpha \le 10$), 常数$r \in (0,1)$, 精度$\varepsilon > 0$, 令$k := 1$。

Step2:以 x^{k-1} 为初始点，求解无约束优化问题

$$\min_{x \in R^n} \varphi(x, v^k, \mu^k) = f(x) + \sum_{i=1}^{l} v_i^k h_i(x) + \mu^k \sum_{i=1}^{l} h_i^2(x)$$

得到其最优解$x^*(\mu^k, v^k)$，记为 x^k。

Step3：如果 $||h(x^k)|| \le \varepsilon$, 则 x^k 就是最优解，stop; 否则，计算 $\beta = ||h(x^k)||/||h(x^{k-1})||$, 若$\beta \le r$, 转step4, 若$\beta > r$, 令$\mu^{k+1} = \alpha\mu^k$，转 step4.

Step 4：计算$v_j^{k+1} = v_j^k + \mu^k h_j(x)$,$j = 1,2,\cdots,l$, $k := k+1$, 转 step2.

典型优化软件

SDPT3: 基本代码是 MATLAB，求解锥规划问题，主要实现的算法是一种原始 - 对偶内点法.
MOSEK: 求解线性规划、二次锥规划、半定规划、二次规划等凸优化问题，以及混合整数线性规划和混合整数二次规划等,重点是求解大规模稀疏问题.
CPLEX: 求解整数规划问题，非常大规模的线性规划问题(使用单纯形方法或者内点法),(非)凸二次规划问题，二次锥规划问题.
Gurobi: 求解线性规划、二次(约束)规划、混合整数线性规划、混合整数二次(约束)规划.
POPT: 求解大规模非线性规划问题,主要实现了原始-对偶内点法,并使用滤波方法代替线搜索.
Knitro: 求解大规模非线性优化问题,，可以用来求解一般非凸非线性规划问题，非线性方程组，线性规划，二次(线性)约束二次规划问题，线性(非线性)最小二乘问题，混合整数规划问题以及无导数优化问题等.

第二章

完